



TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin bilimsel niteliği, yöntemi, proje yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Ecesu BAŞAK
Araştırma Önerisinin Başlığı: Derin Öğrenme Tabanlı Görüntü Analizi ile Şerbetçiotu (<i>Humulus lupulus</i>) Bitkisinde Hastalık ve Zararlı Böcek Tespiti
Danışmanın Adı Soyadı: Prof. Dr. Uğur YÜZGEÇ
Araştırmanın Yürütüleceği Kurum/Kuruluş: Bilecik Şeyh Edebali Üniversitesi

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Bu araştırma önerisi, Türkiye'de yalnızca Bilecik'in Pazaryeri ilçesinde yetiştirilen ve bira, ilaç ile kozmetik sanayileri için stratejik öneme sahip olan şerbetçiotu (*Humulus lupulus*) bitkisinde, görüntü işleme ve derin öğrenme teknikleri kullanarak hastalık ve zararlı böceklerin erken tespitine yönelik otomatik bir izleme sistemi geliştirmeyi amaçlamaktadır (Almaguer et al., 2014). Bitkinin yaprak biti ve külleme gibi patojenlere karşı hassas olması ve mevcut tespit yöntemlerinin manuel gözleme dayalı olması, geç müdahaleye ve önemli ürün kayıplarına yol açmaktadır. Proje, literatürde şerbetçiotu için hem hastalık hem de zararlı böcek tespitini entegre eden ilk derin öğrenme tabanlı sistem olması nedeniyle yüksek özgün değer taşımaktadır.

Çalışmanın temel yöntemi, açık kaynaklı veri setleri (Kaggle, PlantNet) ile Pazaryeri bölgesinden toplanacak saha görüntülerinin birleştirilerek zenginleştirilmiş bir veri tabanı oluşturulmasına dayanmaktadır. Görüntüler, manuel olarak etiketlenip ön işlemden geçirecek ve %80 eğitim, %20 test olarak ayrılacaktır. Model eğitimi, Python programlama dili ile TensorFlow veya PyTorch kütüphaneleri kullanılacak; ResNet ve EfficientNet gibi gelişmiş evrimsel sinir ağı mimarilerinin performansları doğruluk, kesinlik, duyarlılık ve F1-skoru metrikleri üzerinden karşılaştırılacaktır (Ensari et al., 2020). Modelin genelleme başarısını artırmak amacıyla döndürme, parlaklık ayarı, çevirme ve yakınlaştırma gibi veri artırma teknikleri uygulanacak; veri yetersizliği durumunda Yapay Üretici Ağlar ile sentetik veri üretimi değerlendirilecektir (Gomaa, 2021).

Proje yönetimi, veri toplama ve ön işleme, model eğitimi ve doğrulama ile sonuçların değerlendirilmesi ve raporlanması olmak üzere üç ana aşamada yürütülecektir. İş-zaman çizelgesi 12 aylık bir süreyi kapsamakta olup, her aşama için somut başarı kriterleri belirlenmiştir. Projenin yaygın etkisi çok boyutludur. Bilimsel düzeyde, en az bir hakemli dergide yayımlanacak makale ve bitkiye özgü ilk yerli görüntü veri tabanı oluşturulması hedeflenmektedir. Ekonomik ve sosyal etki olarak, erken uyarı sistemi ile üreticilerin zamanında müdahalesi sağlanacak olup, gereksiz pestisit kullanımı azaltılarak üretim maliyetleri düşürülecek, çevresel sürdürülebilirliğe katkıda bulunulacaktır. Geliştirilecek model ve metodoloji, ileride diğer tarımsal ürünler için de uyarlanabilecek, böylece ulusal tarım teknolojilerinin dijital dönüşümüne ve araştırmacı yetiştirilmesine katkı sağlayacaktır.

Anahtar Kelimeler: Şerbetçiotu, Görüntü İşleme, Derin Öğrenme, Yapay Zeka, Hastalık Tespiti

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Bu araştırma önerisi, Türkiye'de yalnızca Bilecik'in Pazaryeri ilçesinde yetiştirilen ve bira, ilaç ile kozmetik sanayileri için stratejik öneme sahip olan şerbetçiotu (*Humulus lupulus* L.) bitkisinde, yaprak biti ve külleme gibi zararlı ve hastalıkların erken ve doğru tespitine yönelik bütünsel bir derin öğrenme modeli geliştirmeyi amaçlamaktadır. Konunun önemi bu bitkinin ülkemizdeki tek yetiştirme alanının sınırlı olması, mevcut tespit yöntemlerinin manuel gözleme dayalı olması nedeniyle geç müdahaleye ve ciddi ürün kayıplarına yol açabilmesi, dolayısıyla hem üretici ekonomisini hem de yerli sanayinin hammadde arz güvenliğini tehdit etmesinden kaynaklanmaktadır. Literatür incelendiğinde, Türkiye'de şerbetçiotu için derin öğrenme tabanlı bir zararlı/hastalık tespit sistemi bulunmamaktadır. Mevcut uluslararası ve yerel çalışmalar (örneğin, ODTÜ ve Ankara

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

Üniversitesi'nin 2022 tarihli hastalık sınıflandırma çalışması ve Brezilya'daki 2024 tarihli azot konsantrasyonu tahmin çalışması) ya sadece hastalıkları ya da besin içeriğini ele almakta, ancak hem hastalık hem de zararlı böcek tespitini aynı anda ve bütüncül bir şekilde gerçekleştiren bir model önermemektedir (Aydın, Yılmaz, 2022; Nagel ve ark., 2024). Bu araştırma, literatürdeki bu eksiği gidermek amacıyla, hem hastalık hem de zararlıları tek bir modelde tespit edebilen özgün ve kapsamlı bir yapay zeka çözümü geliştirmeyi hedeflemektedir.

Bu bağlamda araştırma sorusu "Şerbetçiotu bitkisinde, derin öğrenme modelleri kullanılarak hem yaprak hastalıklarını hem de zararlı böcekleri yüksek doğrulukla ve aynı anda tespit edebilen otomatik bir sistem geliştirilebilir mi?" şeklinde tanımlanmaktadır. Hipotez olarak ResNet ve EfficientNet gibi gelişmiş derin öğrenme mimarilerinin, oluşturulacak kapsamlı ve özgün bir veri seti üzerinde eğitilmesiyle, bu çoklu tespit görevinin başarılı bir şekilde gerçekleştirilebileceği ve mevcut yöntemlere kıyasla daha yüksek doğruluk ve erken uyarı imkanı sağlanacağı öne sürülmektedir.

Projenin kapsamı açık kaynaklı veri setlerinden ve Bilecik'teki tarlalardan toplanacak özgün görüntülerle zenginleştirilmiş kapsamlı bir veri tabanı oluşturulmasını, Python, TensorFlow/Keras ortamında ResNet ve EfficientNet mimarileri temel alınarak model eğitilmesini ve model performansının accuracy, precision, recall, F1-score gibi metriklerle değerlendirilmesini içermektedir. Çalışmanın bilimsel niteliği, Türkiye'de şerbetçiotu için bir ilk olan bu yerli veri seti ve entegre yapay zeka modeli ile sadece akademik bir katkı sunmakla kalmayıp, aynı zamanda tarımsal uygulamalara doğrudan aktarılabilir pratik ve yenilikçi bir çözüm üretmesinden gelmektedir. Son olarak, bu proje 12. Kalkınma Planında vurgulanan "tarımda dijital dönüşümün yaygınlaştırılması" ve "yerli kaynaklarla katma değerli üretim" hedefleri ile doğrudan örtüşmektedir. Ayrıca, 2030 Sanayi ve Teknoloji Stratejisi'nin "Yapay Zeka" ve "Tarım Teknolojileri" başlıkları altında önceliklendirdiği, ileri teknolojilerin tarımda kullanımını teşvik ederek kaynak verimliliğini artırma ve sürdürülebilirliği sağlama amaçlarına doğrudan hizmet etmektedir. Bu stratejik belgelerle uyumu, projenin ulusal kalkınma hedeflerine sağlayacağı katkısı ve bilimsel-teknolojik altyapımızın güçlenmesine yönelik potansiyelini daha da belirginleştirmektedir.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Türkiye'de sadece Bilecik Pazaryeri'nde yetiştirilen ve stratejik öneme sahip şerbetçiotu bitkisinde, derin öğrenme tabanlı bir görüntü analiz sistemi geliştirilerek hastalık ve zararlı böceklerin erken teşhisini sağlamak, böylece ürün kayıplarını ve gereksiz ilaç kullanımını azaltmak, verimi artırmak ve dijital tarım uygulamalarının yaygınlaşmasına katkı sağlamaktır. Projenin özel amaçları ise:

1. Şerbetçiotu bitkisine özgü, "sağlıklı", "hastalıklı" (külleme vb.) ve "zararlı böcek bulunan" sınıflarını içeren, açık kaynaklı ve sahaya özgü görüntülerle zenginleştirilmiş kapsamlı ve etiketli bir görüntü veri tabanı oluşturmak.
2. Bu veri tabanı kullanılarak hem hastalık hem de zararlı böcek tespitini aynı anda yapabilen çok sınıflı bir derin öğrenme modeli (ResNet, EfficientNet) eğitmek.
3. Modelin performansını doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1-skoru gibi nicel metriklerle değerlendirilerek, en az %85 doğruluk oranına ulaşmak.
4. Modelin genelleme yeteneğini artırmak için veri artırma (data augmentation) tekniklerini (döndürme, çevirme, ölçeklendirme) sistematik olarak uygulamak ve veri yetersizliği durumunda sentetik veri üretimini değerlendirmek.

Proje hedefleri aşağıda verilmektedir:

1. En az iki farklı açık kaynaklı platformdan (Kaggle, PlantNet) ve yerel saha çekimlerinden toplanmış, en az 1.500 adet etiketli görüntüden oluşan bir veri seti oluşturmak.
2. EfficientNet-B3 ve ResNet-50 mimarilerini fine-tuning yöntemiyle eğitmek ve bu modellerin performanslarını karşılaştırmalı olarak analiz etmek.
3. Test veri seti üzerinde en başarılı modelden %85 ve üzeri doğruluk, %80 ve üzeri F1-skoru elde etmek.

Bu proje, öncelikle Türkiye'de şerbetçiotu tarımını doğrudan tehdit eden hastalık ve zararlı böcek problemlerine yönelik acil ve yenilikçi bir çözüm ihtiyacından doğmaktadır. Literatürde, bu stratejik bitki için hem hastalık hem de zararlı böcek tespitini entegre bir şekilde ele alan derin öğrenme tabanlı bir modelin bulunmaması, projenin temel özgünlük gerekçesini oluşturmaktadır. Önerilen yöntem ve kullanılacak araçların (Python, açık kaynak kütüphaneler, bulut bilişim platformları) proje süresi ve kapsamı dahilinde erişilebilir ve uygulanabilir olması, çalışmanın teknik fizibilitesini güçlü bir şekilde desteklemektedir. Ayrıca, geliştirilecek model ve oluşturulacak veri tabanı, yalnızca şerbetçiotu ile sınırlı kalmayıp ileride diğer tarımsal ürünlere de uyarlanabilecek bir altyapı sunarak, uzun vadede bilimsel, çevresel ve ekonomik sürdürülebilirliğe önemli bir katkı potansiyeli taşımaktadır.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Bu araştırmada, şerbetçiotunda hastalık ve zararlı böcek tespiti için derin öğrenme tabanlı bir görüntü sınıflandırma modeli geliştirilmesi planlanmaktadır. Önerilen yöntem, Aydın ve Yılmaz (2022)'in şerbetçiotu yaprak hastalıklarında veri seti iyileştirmenin derin öğrenme başarısına etkisini incelediği çalışması ile Nagel ve ark. (2024)'nin şerbetçiotunda RGB görüntüler kullanarak besin içeriği tahmini yaptığı araştırmadan esinlenmekte olup, bu çalışmaların ötesine geçerek hem hastalık hem de zararlı böcek tespitini tek bir bütünleşik modelde gerçekleştirmesiyle özgünleşmektedir.

Çalışma, deneysel bir araştırma tasarımına sahiptir. Süreç, bir veri setinin oluşturulması, bu veri seti kullanılarak birden fazla derin öğrenme modelinin eğitilmesi, modellerin performanslarının karşılaştırmalı olarak değerlendirilmesi ve en başarılı modelin saha koşullarına yakın görüntülerle test edilmesi aşamalarından oluşmaktadır.

Araştırmanın modelleme aşamasında; bağımlı değişken, her bir girdi görüntüsü için model tarafından tahmin edilmesi hedeflenen "sağlıklı", "küllenme hastalıklı" ve "yaprak biti zararlılığı" sınıf etiketlerinden oluşmaktadır. Bağımsız değişkenler ise bu tahmini besleyen girdiler olup, ham görüntüleri oluşturan piksel değerleri matrisinin yanı sıra, bu görüntülere uygulanan ön işlemler (yeniden boyutlandırma ve normalizasyon) ve modelin genelleme kapasitesini güçlendirmek amacıyla kullanılan veri artırma teknikleri (döndürme, çevirme, parlaklık ayarı vb.) ile elde edilen tüm modifiye görüntü setlerini kapsamaktadır.

Çalışmanın temelini, açık kaynaklı platformlar olan Kaggle (Napa, 2023; Scruggzilla, 2022) ve PlantNet (2025)'ten temin edilecek görüntüler ile Bilecik Pazaryeri'ndeki şerbetçiotu tarlalarından proje süresince toplanacak özgün saha görüntüleri oluşturacaktır. Toplanan tüm görüntüler manuel olarak etiketlenecek ve 224x224 piksel gibi standart boyutlara yeniden ölçeklendirilecektir. Piksel değerleri [0, 1] veya [-1, 1] aralığına normalize edilecektir. Modelin genelleme başarısını artırmak ve veri seti boyutunu yapay olarak büyütme için döndürme, yatay-dikey çevirme, yakınlaştırma ve parlaklık değişimi gibi veri artırma (data augmentation) teknikleri sistematik olarak uygulanacaktır (Barbedo, 2018). Veri seti, eğitim (%80) ve test (%20) olarak ayrılacaktır.

Model eğitimi için Python programlama dili ve TensorFlow/PyTorch derin öğrenme kütüphaneleri kullanılacaktır. Transfer öğrenme yöntemiyle, ImageNet veri seti üzerinde önceden eğitilmiş olan ResNet-50 ve EfficientNet-B3 mimarileri temel alınacaktır. Bu modellerin son katmanları, projemize özgü 3 sınıfı (sağlıklı, hastalıklı, zararlı) ayırt edecek şekilde değiştirilecek ve fine-tuning (ince ayar) yapılarak yeniden eğitilecektir. Eğitim sırasında aşırı öğrenmeyi (overfitting) önlemek için Early Stopping ve Model Checkpointing gibi yöntemler kullanılacak, doğrulama (validation) veri seti üzerinden model performansı sürekli izlenecektir.

Model performansının değerlendirilmesi için kullanılacak olan metrikler nicel ve istatistiksel temellidir. Modelin genel başarısı Doğruluk (Accuracy) ile ölçülecektir. Sınıflar arası dengesizlik durumunda daha güvenilir bir ölçüt olan F1-Skoru temel performans göstergesi olarak kabul edilecektir. Ayrıca, modelin güvenilirliğini detaylı analiz etmek için Kesinlik (Precision) ve Duyarlılık (Recall) metrikleri hesaplanacak ve her bir sınıf için ayrı ayrı Karmaşıklık Matrisi (Confusion Matrix) oluşturulacaktır. Model çıktılarının istatistiksel güvenilirliği, test seti üzerinden elde edilen bu metriklerin raporlanmasıyla sağlanacaktır.

Proje öncesinde, benzer bitki hastalığı tespiti çalışmalarını inceleyen kapsamlı bir literatür taraması yapılmış ve kullanılacak metodolojinin teknik fizibilitesi değerlendirilmiştir (Mohanty et al., 2016; Ferentinos, 2018; Abade et al., 2019; Kaur et al., 2019; Ensari et al., 2020). Açık kaynak kodları ve veri setlerine erişimin mümkün olduğu, seçilen derin öğrenme mimarilerinin bu tür görüntü sınıflandırma problemlerinde kanıtlanmış başarısı, projenin uygulanabilir olduğunu göstermektedir.

Sunulan yöntem, çalışma takviminde belirtilen iş paketleriyle doğrudan ilişkilidir:

- Veri Toplama ve Hazırlama : Yöntemin "Veri Toplama ve Hazırlama" aşamasını kapsar.
- Model Eğitimi ve Doğrulama : "Model Eğitimi ve Doğrulama" ile "İstatistiksel Yöntemler"in eğitim ayağını kapsar.
- Model Testi ve Değerlendirme : "İstatistiksel Yöntemler ve Model Değerlendirme" aşamasının test ve nihai raporlama kısmını oluşturur.
- Saha Uygulama Simülasyonu : Geliştirilen modelin, yöntemde belirtilen bağımsız değişkenler (saha görüntüleri) karşısındaki performansının gerçek dünya koşullarında sınanmasına karşılık gelir.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmacının başarısına katkısı "Çalışma Takvimi" doldurularak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmacının Başarısına Katkısı***
15.05-15.08.2026	Veri setinin oluşturulması ve ön işleme • Açık kaynaklı veri setlerinden görüntülerin toplanması • Sahadan örnek görüntü çekimlerinin yapılması • Tüm görüntülerin manuel olarak etiketlenmesi • Görüntülere ön işlem uygulanması	Ecesu BAŞAK	En az 1.500 etiketli görüntüden oluşan dengeli veri seti oluşturulması (%20)
16.08-15.12.2026	Model geliştirme ve eğitim • Model mimarilerinin hazırlanması • Veri artırma tekniklerinin uygulanması • Modellerin transfer öğrenme ile eğitilmesi • Doğrulama metriklerinin izlenmesi	Ecesu BAŞAK	Modellerin doğrulama setinde en az %80 doğruluk performansı elde edilmesi (%30)
16.12.26-15.02.27	Model testi ve değerlendirme • Test seti ile nihai performans değerlendirmesi • Performans metriklerinin hesaplanması • Karmaşıklık matrisi oluşturulması • Karşılaştırmalı analiz	Ecesu BAŞAK	Test setinde en az %85 doğruluk ve %80 F1-Skoru elde edilmesi (%25)
16.02-15.05.2027	Saha uygulama Simülasyonu • Modelin saha görüntülerinde test edilmesi • Tahmin doğruluğunun kontrolü • Sistem davranışının gözlemlenmesi	Ecesu BAŞAK	Saha görüntülerinde %75+ doğruluk elde edilmesi (%25)

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.

(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

3.2 Risk Yönetimi

Araştırmacının başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmacının başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmacının temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
-------------------	------------------------------

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Açık kaynaklı veri setlerinde şerbetçiotu görüntülerinin sınırlı olması veya sınıflar (sağlıklı/hastalıklı/zararlı) arasında ciddi dengesizlik bulunması. Sahadan yeterli sayıda ve kalitede görüntü toplanamaması.	Sadece 1-2 veri setiyle sınırlı kalmayıp, Kaggle, PlantNet, GitHub vb. tüm erişilebilir kaynaklar taranacak ve birleştirilecektir. Veri artırma tekniklerine ek olarak, sınırlı olan sınıflar için GAN tabanlı sentetik görüntü üretimi değerlendirilecektir (Barbedo, 2018).
Seçilen derin öğrenme mimarilerinin (ResNet, EfficientNet) veri seti üzerinde beklenen %85 doğruluğa ulaşamaması veya aşırı öğrenme (overfitting) sorunu yaşanması.	Farklı model mimarileri (VGG, DenseNet) test edilecek ve hiperparametre optimizasyon araçları (Grid Search, Random Search) kullanılacaktır. Aşırı öğrenmeyi engellemek için Dropout katmanları, L2 regularizasyonu ve daha kapsamlı veri artırma yöntemleri kullanılacaktır.
Model eğitimi için gerekli olan GPU (Graphics Processing Unit) kaynağının yetersiz kalması, bu da eğitim sürelerini uzatabilir veya model karmaşıklığını kısıtlayabilir.	Google Colab Pro, Kaggle Notebooks veya AWS, Google Cloud gibi bulut tabanlı GPU hizmetlerinden yararlanılacaktır. Gerekirse, daha az parametreye sahip ve daha hızlı eğitilen "hafif" model mimarileri (MobileNetV2, EfficientNet-Lite) denenebilir.
Laboratuvar ortamında yüksek performans gösteren modelin, gerçek tarla koşullarında (farklı ışık, açı, arka plan, toz vs.) başarısız olması.	Model eğitime, mümkün olduğunca erken aşamada, gerçek saha görüntüleri de dahil edilecektir. Eğitim sırasında, saha koşullarını taklit eden (gürültü ekleme, bulanıklaştırma, renk değişimi vb.) daha gelişmiş veri artırma teknikleri kullanılacaktır.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Bilgisayar Laboratuvarı (Yüksek Performanslı PC ve GPU destekli sistemler)	Yazılım geliştirme, derin öğrenme modeli eğitimi, veri ön işleme ve kapsamlı veri analizi süreçlerinin yürütülmesi.
Bilecik Şeyh Edebali Üniversitesi Kütüphanesi	Literatür taraması, akademik kaynaklara erişim ve metodolojik karşılaştırmalar yapılacaktır.
Üniversite Kampüs Ağı ve Yüksek Hızlı İnternet Altyapısı	Büyük veri setlerinin indirilmesi, bulut bilişim kaynaklarına erişim ve çevrimiçi derin öğrenme platformlarının (Google Colab, Kaggle) etkin kullanımı.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	- Proje sonuçlarını içeren ve şerbetçiotu için geliştirilen metodolojiyi detaylandıran bir makalenin, uluslararası indekslerde taranan hakemli bir dergide yayımlanması. - Elde edilen bulguların, ulusal/uluslararası bir kongrede bir tam metin sözlü bildiri olarak sunulması.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	- Şerbetçiotu hastalık ve zararlılarına yönelik oluşturulacak ilk kapsamlı, etiketli ve halka açık görüntü veri tabanı. - Bir web arayüzü veya mobil uygulama ile entegre edilebilecek, çalışır durumda bir yapay zeka modeli prototipi.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	• Geliştirilen metodolojinin, TÜBİTAK 1002 (Hızlı Destek) veya TÜBİTAK 1501 (Sanayi Ar-Ge) gibi programlar kapsamında, farklı tarımsal ürünlere (örneğin, buğday, elma) uyarlanmasına yönelik yeni bir proje önerisi hazırlanması.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

6. EKLER

EK-1: KAYNAKLAR

- Abade, A, S., A. Almeida and F. Vidal. 2019. Plant diseases Recognition from Digital Images using Multichannel Convolutional Neural Networks. In: Proceedings of the 14th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications. VISIGRAPP. pp. 450-458.
- Almaguer, C.; Schönberger, C.; Gastl, M.; Arendt, E.K.; Becker, T. Humulus lupulus—A Story That Begg to Be Told. A Review. J. Inst. Brew. 2014, 120, 289–314. [Google Scholar] [CrossRef]
- Aydin, E., & Yilmaz, B. (2022). The effect of improvement of datasets on accuracy achievement in deep learning: An example of disease detection in hops plant. Journal of Global Innovations in Agricultural Sciences, 10(1), 1–7. <https://doi.org/10.22194/JGIAS/10.966>
- Barbedo, J. G. A. 2018. Factors influencing the use of deep learning for plant disease recognition. Biosystems Engineering. 172:84-91.
- Barbedo, J. G. A. 2018. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. Computer Electronics in Agriculture. 153:46-53.
- Ensari, T., C. D. Armah, A. E. Balsever, M. Dagtekin. 2020. Convolutional Neural Networks for ImageBased Digital Plant Phenotyping. European Journal of Science and Technology. Special Issue:338-342.
- Ferentinos, K. P. 2018. Deep learning models for plant disease detection and diagnosis. Comput. Electron. Agriculture.145:311-318
- Gomaa, A. A. 2021. Early Prediction of Plant Diseases using CNN and GANs. International Journal of Advanced Computer Science and Applications (IJACSA).12/5:514- 519.
- Kaur, S., S. Pandey and S. Goel. 2019. Plants Disease Identification and Classification through Leaf Images: A Survey. Archives of Computational Methods in Engineering. 26:507-530

Mohanty, S. P., D. P. Hughes and M. Salathé. 2016. Using deep learning for image-based plant disease detection. *Front Plant Science*.7:1-10.

Nagel, M., et al. (2024). Classification models for nitrogen concentration in hop (*Humulus lupulus* L.) using RGB image features. *Applied Sciences*, 15(9), 4799. <https://doi.org/10.3390/app15094799>

Napa, A. (2023). Hops Health Image Dataset [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/ankurnapa/hops-health-image-dataset>

PlantNet. (2025). *Humulus lupulus* L. – Image Data. PlantNet Identify. <https://identify.plantnet.org/tr/k-world-flora/species/Humulus%20lupulus%20L./data>

Scruggzilla. (2022). Hops Classification Dataset [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/scruggzilla/hops-classification>